FASHION MNIST: MANERA DE IMPLEMENTARLO CON UNA RED NEURONAL CONVOLUCIONAL

```
import pandas as pd

trainData = pd.read_csv('fashion-mnist_train.csv')
testData = pd.read_csv('fashion-mnist_test.csv')
```

1. CONJUNTO DE DATOS

Nuestro conjunto de datos esta formado por 70.000 imágenes, el cual está dividido en dos subconjuntos: **train** y **test**. Los conjuntos de datos tienen las siguientes características:

- **Train:** Se utilizará para entrenar el modelo. Este set contiene el 85% de todas las imagenes, es decir, un total de 60.000 imágenes donde cada una esta formada por 784 píxeles.
- **Test:** Se utilizará para probar el modelo. Este set contiene el 15% de todas las imagenes, es decir, un total de 10.000 imágenes donde cada una esta formada por 784 píxeles.

1.1 Categorias de los datos

Índice	Categoria
0	Camiseta / top
1	Pantalón
2	Jersey
3	Vestido
4	Abrigo
5	Sandalia
6	Camisa
7	Zapatilla de deporte
8	Bolsa
9	Botín

QUICK VIEW DE LOS DATOS

Lo primero que debemos hacer es vizualizar las dimensiones del dataset:

```
print('\t Filas,  Columnas', )
print('Train:\t', trainData.shape)
print('Test:\t', testData.shape)
```

```
            Filas,  Columnas
    Train:   (60000, 785)
    Test:    (10000, 785)
```

Hay que verificar si hay datos faltantes en el dataset:

```
def verificar_nulos(data):
  if data.isnull().any().any() == False:
    return print('Los datos NO CONTIENEN VALORES NULOS')
  else:
    return print('Los datos SI CONTIENEN VALORES NULOS')

verificar_nulos(trainData)
verificar_nulos(testData)
```

```
    Los datos NO CONTIENEN VALORES NULOS
    Los datos NO CONTIENEN VALORES NULOS
```

2. Distribucion por clases

No menos importante es visualizar la matriz de datos, pues nos es imprescindible para manejarlos y saber con cual de las columnas asociar las etiquetas. Para ello, mostramos las 3 primeras y últimas filas del data set Train (idem por el test):

```
trainData.head(4).append(trainData.tail(3))
```

	label	pixel1	pixel2	pixel3	pixel4	pixel5	pixel6	pixel7	pixel8	pixel9	...	pixel775	pixel776	pixel777	pixel778	pixel779	pixel780	pi
0	2	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	
1	9	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	
2	6	0	0	0	0	0	0	0	5	0	...	0	0	0	30	43	0	
3	0	0	0	0	1	2	0	0	0	0	...	3	0	0	0	0	1	
59997	8	0	0	0	0	0	0	0	0	0	...	160	162	163	135	94	0	

Como se observa la primera columna nos indica que tipo de prenda es, por lo cual crearemos un diccionario referenciando hacia que tipo de prenda hace referencia el numero.

Por siguiente añadiremos el dato cualitativo al dataset.

```
labels = {  0: "Camiseta",
            1: "Pantalon",
            2: "Jersey",
            3: "Vestido",
            4: "Abrigo",
            5: "Sandalia",
            6: "Camisa",
            7: "Zapatilla de deporte",
            8: "Bolsa",
            9: "Botines"
}

n_cat = len(labels)

def add_column_from_dict(data, col, new_col, dict_):
    data[new_col] = data[col].map(dict_)
    return data

add_column_from_dict(trainData, 'label', 'labelName', labels)
add_column_from_dict(testData, 'label', 'labelName', labels)
```

	label	pixel1	pixel2	pixel3	pixel4	pixel5	pixel6	pixel7	pixel8	pixel9	...	pixel776	pixel777	pixel778	pixel779	pixel780	pixel781	pi
0	0	0	0	0	0	0	0	0	9	8	...	87	56	0	0	0	0	
1	1	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	
2	2	0	0	0	0	0	0	14	53	99	...	0	0	0	63	53	31	
3	2	0	0	0	0	0	0	0	0	0	...	126	140	0	133	224	222	
4	3	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	
9995	0	0	0	0	0	0	0	0	0	0	...	23	14	20	0	0	1	
9996	6	0	0	0	0	0	0	0	0	0	...	0	0	2	52	23	28	
9997	8	0	0	0	0	0	0	0	0	0	...	172	172	182	199	222	42	
9998	8	0	1	3	0	0	0	0	0	0	...	0	0	0	0	1	0	
9999	1	0	0	0	0	0	0	0	140	119	...	95	75	44	1	0	0	

10000 rows × 786 columns

Veremos en un grafico como esta la distribucion de prendas de ropa segun el conjunto de los datos.

```
import matplotlib.pyplot as plt

def pie_plot(data, plotTitle):

    aux = data['labelName'].value_counts().to_frame('Freq')
    aux['labelName'] = aux.index
    valores = aux['Freq']

    def pct_abs(values):
        def funct(pct):
            total = sum(values)
            val = int(round(pct * total / 100.0))
            return '{p:.2f}%\n({v:d} it'.format(p = pct,v = val)
        return funct


    plt.figure(figsize = (16,8))

    ax1 = plt.subplot(121, aspect = 'equal')
    aux.plot(kind = 'pie',
             y = 'Freq',
             ax = ax1,
             autopct = pct_abs(valores),
             labels = aux['labelName'],
             legend = False,
             title = plotTitle,
             fontsize = 10)
```

```
    # plot table
    ax2 = plt.subplot(122)
    plt.axis('off')
    plt.show()


plot1 = pie_plot(trainData,'Distribución de la ropa para el conjunto de datos TRAIN')
plot2 = pie_plot(testData, 'Distribución de la ropa para el conjunto de datos TEST')
plt.show()
```

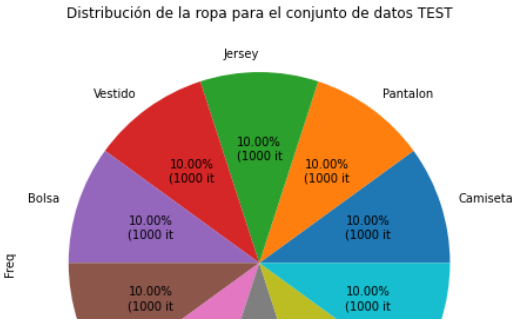

Visualizando la matriz como imagenes

Procedemos a crear una funcion que nos graficara la prenda seleccionando una fila de la matriz (1 fila = 1 prenda). Para ello, redimensionaremos la fila de pixeles (una fila = una imagen, es decir, un vector $V = (v_1, v_2, \ldots, v_n)$ donde $n = 784$) a una matriz de l $\in$ M $_{m,n}$, donde $m, n = 28$.

```
import numpy as np

def plot_image_sample(data, label_number, DataSetType, pf, pc):

    type_data = ('TRAIN' if DataSetType.lower().find("train") == label_number else 'TEST')

    # Obtenemos la etiqueta (diccionario)
    etiqueta = labels[label_number]
    # Eliminamos la primera columna (codigo etiqueta) y la última (nombre etiqueta)
    aux = data[data["label"] == label_number].sample(1)
    aux2 = aux.iloc[:, 1:-1]
    img = np.array(aux2).reshape(pf, pc)

    plt.imshow(img, cmap = 'gray')
    plt.grid(True)
    plot = plt.title('Ropa: ' + str(etiqueta) + '\nDatos: ' + str(type_data))


def matrix_image_sample(data, label_number, pf ,pc):

    pd.options.display.max_columns = None
    aux = data[data["label"] == label_number].sample(1)
    aux2 = aux.iloc[:, 1:-1]
    img = pd.DataFrame(np.array(aux2).reshape(pf, pc))

    return img
```

Muestra train

Como ya hemos hablado antes, mostramos la imagen con una dimension de 28x28. Para ello, definimos dos parametros ***pf*** y ***pc***:

- **pf** $\rightarrow$ 28 (*píxeles fila*)

- **pc** $\longrightarrow$ 28 (*píxeles columna*)

Procedemos a visualizar para una prenda de ropa su matrix de datos y su apariencia real:

```
pf = 28
pc = 28

plot_image_sample(trainData, 9, 'train', pf, pc)
matrix_image_sample(trainData, 9, pf, pc)
```

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
4	0	0	0	0	0	0	0	0	0	0	0	0	0	39	182	146	131	111	0	0	0	0	0	0	5	0	1	0
5	0	0	0	0	0	0	0	0	0	0	0	0	0	167	235	222	234	255	153	162	196	206	192	215	183	0	0	0
6	0	0	0	0	0	0	0	0	0	0	2	0	0	219	213	209	208	223	174	255	236	235	231	238	180	0	0	0
7	0	0	0	0	0	0	0	0	0	0	2	0	46	243	209	224	226	233	175	223	213	223	219	231	198	0	0	0
8	0	0	0	0	0	0	0	0	0	0	0	0	122	220	196	213	226	224	176	236	226	224	224	223	255	6	0	1
9	0	0	0	0	0	0	0	0	0	1	0	0	219	213	200	210	228	226	197	236	224	224	227	214	238	116	0	0
10	0	0	0	0	0	0	0	0	0	2	0	52	254	201	211	222	230	214	195	227	219	221	204	219	227	225	0	0
11	0	0	0	0	0	0	0	0	0	0	0	145	214	188	209	211	233	207	206	230	221	217	215	226	213	231	48	0
12	0	0	0	0	0	0	0	0	0	0	0	223	203	202	216	206	236	201	216	222	207	203	209	217	214	234	165	0
13	0	0	0	0	0	0	0	0	2	0	85	253	204	221	215	218	237	192	217	217	199	201	216	229	229	228	248	0
14	0	0	0	0	0	0	0	0	0	0	195	216	214	227	205	214	234	186	223	218	219	223	227	225	228	219	255	26
15	0	0	0	0	0	0	0	0	0	99	252	208	224	214	209	231	221	188	231	217	221	217	220	221	234	221	255	79
16	1	0	0	0	5	3	5	0	22	241	207	211	214	205	206	231	218	198	236	213	221	228	224	218	208	192	226	75
17	0	2	6	0	0	0	0	0	205	229	193	222	196	205	209	243	200	196	217	228	225	210	194	196	197	192	234	34
18	0	0	0	0	0	0	24	177	234	212	211	208	224	230	220	234	203	227	255	212	189	195	200	203	203	206	223	0
19	0	0	76	138	158	199	223	215	212	226	208	218	239	232	227	217	231	254	98	0	184	230	201	205	201	208	190	0
20	0	171	206	192	195	194	181	189	200	212	207	211	230	228	229	231	169	0	0	0	222	209	204	201	198	210	140	0
21	55	224	206	207	208	210	218	226	224	228	222	218	225	230	241	73	0	0	0	0	198	208	203	204	206	218	86	0
22	90	219	196	215	242	242	248	247	246	250	248	247	233	166	0	0	0	3	0	12	238	191	222	222	186	237	47	0
23	0	0	27	51	89	106	120	129	125	108	84	48	11	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0
24	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
25	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
26	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
27	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

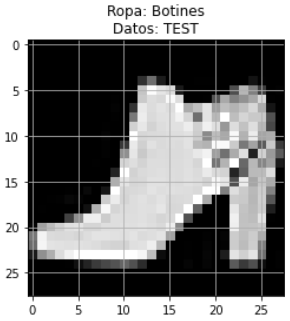

Muestra del Test

```
plot_image_sample(testData, 3, 'Test', pf, pc)
matrix_image_sample(testData, 3, pf, pc)
```

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27
0	0	0	0	0	0	1	0	0	0	0	0	76	39	6	0	0	0	17	109	88	2	12	63	0	0	0	0	0
1	0	0	0	0	0	4	0	120	160	134	178	250	198	213	195	171	249	211	205	213	205	192	190	80	0	4	0	0
2	0	0	0	0	0	6	0	101	213	186	168	170	176	186	196	194	195	196	160	167	167	171	161	112	0	8	0	0
3	0	0	0	0	0	6	0	83	195	190	166	191	164	190	178	166	142	153	164	170	163	161	179	83	0	8	0	0
4	0	0	0	0	0	5	0	49	180	161	184	195	209	192	171	174	173	189	228	210	175	172	184	70	0	8	0	0
5	0	0	0	0	0	0	0	0	119	201	209	234	197	190	198	195	205	238	201	189	187	173	90	0	0	0	0	0
6	0	0	0	0	0	0	1	0	16	186	187	187	190	196	147	192	182	168	130	151	172	163	0	0	3	2	0	0
7	0	0	0	0	0	0	1	0	42	215	186	164	128	170	156	209	179	170	144	187	183	195	24	0	2	2	0	0
8	0	0	1	0	0	0	5	0	56	181	183	167	174	153	170	182	211	150	191	195	164	166	55	0	3	0	0	0
9	0	0	1	0	0	0	0	0	111	187	166	120	151	160	164	172	142	160	152	176	157	163	72	0	6	0	0	0
10	0	0	0	0	0	0	0	0	176	172	128	172	161	136	161	168	143	172	170	176	125	173	94	0	8	0	0	0
11	0	0	0	0	0	1	0	0	202	168	152	133	153	149	183	134	148	161	151	137	148	152	141	0	0	0	0	0
12	0	0	1	0	0	2	0	0	164	167	179	181	166	133	203	126	166	181	151	136	141	147	173	0	0	3	0	0
13	0	0	1	1	0	2	0	0	180	171	140	165	150	157	149	138	149	133	140	175	130	153	175	13	0	2	0	0
14	0	0	0	1	0	1	0	31	202	165	160	148	158	130	161	153	197	133	155	165	170	165	180	52	0	4	0	0
15	0	0	0	0	0	3	0	78	199	148	172	183	171	159	127	163	197	192	187	145	116	136	163	87	0	2	0	0
16	0	0	0	0	0	0	0	70	197	168	209	197	190	173	148	212	192	164	144	158	161	166	161	178	0	0	0	0
17	0	0	0	110	137	112	88	125	145	144	141	120	132	149	136	106	179	176	125	150	175	174	157	171	39	0	0	0
18	0	0	0	140	134	130	147	138	112	103	120	122	114	116	124	102	149	190	180	203	205	196	175	187	183	0	0	0
19	0	0	9	150	119	117	116	125	104	119	111	129	99	124	109	97	132	255	156	137	182	150	182	158	188	32	0	0
20	0	0	37	151	116	130	116	124	107	125	111	143	113	113	104	120	109	161	181	151	188	151	194	174	160	133	0	0
21	0	0	36	143	127	114	111	116	120	119	110	134	124	122	129	99	112	172	141	141	142	178	163	168	145	178	25	0
22	0	0	0	129	170	153	136	112	127	130	130	125	147	132	143	148	147	137	151	190	130	196	206	173	143	194	144	0
23	0	0	0	0	48	145	156	103	124	116	127	129	130	87	101	134	158	160	128	183	136	145	171	168	163	137	17	0
24	0	0	1	0	0	83	174	134	138	128	116	141	121	159	194	164	158	147	153	173	164	172	201	179	121	0	0	0
25	0	0	0	2	0	0	151	147	125	134	126	137	136	205	176	164	172	171	176	168	152	104	88	6	0	0	0	0
26	0	0	0	0	5	0	76	183	136	151	144	175	62	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0
27	0	0	1	0	0	1	0	16	60	64	63	44	0	0	1	0	0	0	0	0	0	0	6	2	0	0	0	0

5. PREPROCESAMIENTO DE LOS DATOS

```
 0  5  10  15  20  25
```

```
import keras

def preprocesamiento(data, pf, pc):

    out_Y = keras.utils.to_categorical(data.label, len(labels))
    x_vect = data.values[:,1:-1]  #transformamos el dataFrame en un ndarray, seleccionando solo los píxeles
    x_scaled = x_vect / 255 # Dividimos por 255 por literatura (convergencia del gradiente, evita le colapso)
    n_img = data.shape[0]
    out_X = x_scaled.reshape(n_img, pf, pc, 1) # redimensionamos el vector a (1,784) a (28, 28, 1)

    out_X = out_X.astype(float)
    out_Y = out_Y.astype(float)

    return out_X, out_Y
```

¿Qué es lo que hace ésta función?

Si somos un poco curosos, observamos que:

1. Separamos la variable quantitativa `label` y la asociamos a la variable `out_Y`, la cual devolverá la *respuesta*. Destacar que la respuesta es ahora un vector, por ejemplo, si:
   - `label = 0` ⟶ `(1, 0, 0, 0, 0, 0, 0, 0, 0, 0)`
   - `label = 1` ⟶ `(0, 1, 0, 0, 0, 0, 0, 0, 0, 0)`
   - $\vdots$
   - `label = 9` ⟶ `(0, 0, 0, 0, 0, 0, 0, 0, 0, 1)`

2. Seleccionamos solo las columnas referente a los píxeles, es decir, quitamos las varibles referentes a las etiquetas (`label` y `labelName`). El resultado lo asociamos a la variable `x_vect` .
3. Procedemos a realizar el reescalado de los datos, cogiendo todo el vector y dividiéndola por 255. El resultado lo asociamos a la variable `x_scaled` .
4. Redimensionamos cada una de las imágenes a (28, 28, 1), el formato ideal para introducirlo al modelo

```
x_train, y_train = preprocesamiento(trainData, pf, pc)
x_test, y_test = preprocesamiento(testData, pf, pc)
```

Split del datset train para el entrenamiento del modelo

Normalmente lo que se hace es coger los datos train y dividir dicho set en dos, una parte para entrenar el modelo y otra parte para validarlo. Luego, se predice con los datos test original (no del train)

Es decir, del conjunto de datos total escogemos solo los datos de train y lo dividdmos en 80% y 20%.

Existe una función en **sklearn** que realiza dicho split del dataset automaticamente. Según la literatura (concretamente lo menciona **Aurélien Géron** en el manual **Hand on machine learning with scikit-learn and tensorflow pdf**) el valor de la semilla (si se deseja fijar y mantener su reproducibilidad) se fija normalmente en el valor **42**.

```
from sklearn.model_selection import train_test_split

X_train, X_val, Y_train, Y_val = train_test_split(x_train, y_train, test_size = 0.3, random_state = 42)
```

Unificamos el datatype del vector a un `float`

Ahora, por ejemplo, las distribución de las prendas de ropa es la siguiente:

```
def proc_data_to_plot(data):

    freq = []
    for i in range(len(data)):
        freq.append(np.argmax(data[i]))

    return pd.DataFrame(freq, columns = ['Label'])



Train_labels_to_plot = proc_data_to_plot(Y_train)
Val_labels_to_plot = proc_data_to_plot(Y_val)

Train_labels_to_plot = add_column_from_dict(Train_labels_to_plot, 'Label', 'labelName', labels)
Val_labels_to_plot = add_column_from_dict(Val_labels_to_plot, 'Label', 'labelName', labels)


plot1 = pie_plot(Train_labels_to_plot,'Distribución de la ropa para el conjunto de datos TRAIN')
plot2 = pie_plot(Val_labels_to_plot, 'Distribución de la ropa para el conjunto de datos de VALIDACION')
plt.show()
```

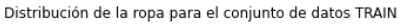

6. MODELO

En python exisen varias maneras de implementar un modelo, en nuestro caso, usearemos el **secuencial** (`model = Sequential()`). Este funciona añadiendo capas de código como se puede observar en el siguiente chunk.

6.1 Partes del Modelo

6.1.1 Modelo Parte 1

- **LeakyReLU**: Definimos la funcion **LeakyReLU** como funcion de activación. Esta función es más eficaz que la ReLU comunmente conocida.
- **Capa convolucional 2D (Conv2D)**:
  - **Filtros**: Numero de filtros (kernels) utilizados en esta capa son 32
  - **kernel_size**: Dimmensión del Kernel: (3 x 3)
  - **activation**: Utilitzamos la función `LeakyReLU`
  - **kernel_initializer**: Función utilizada para inicializarel kernel: `he_normal`. Solo se utiliza en la primera capa. Esta funcion se basa en muestras de una distribución normal truncada centrada en 0 con $sd = \sqrt{(\frac{2}{fan_{in}})}$ donde fan_{in} es el número de unidades de entrada en el tensor ("vector").
  - **input_shape**: Dimensión de la imagen presentada a la CNN: en nuestro caso es una imagen de 28 x 28. La entrada y salida del Conv2D es un tensor 4D.
- **MaxPooling2D**: La capa de reducción o pooling se coloca generalmente después de la capa convolucional. La función principal radica en la reducción de las dimensiones (anchura y altura) de entrada para la siguiente capa convolucional. Esto está muy bien, pero la reducción del volumen de datos conlleva intrínsecamente la pérdida de información, sin embargo, la reducción de la información puede ser algo baneficiós para la red por tres razones:
  - Reduce la sobrecarga de cálculos para las próximas capas de la red
  - Reduce el overfitting (o el sobreajustmanet)
  - Favorece una computación ligera

  Sin alargarme más, en nuestro caso aplicamos un reduccion de (2, 2), reducimos 2 en y y 2 en x
- **Dropout**: En redes neuronales profundas, tener una gran cantidad de parámetros hace que el overfitting tome un rol importante en las predicciones. El overfitting es un problema frecuente que requiere de técnicas para su regulación. Así pues, la técnica de regularización más popular para redes neuronales profundas es, sin duda, el **dropout**. La idea clave es que, en cada uno de los pasos del entrenamiento, desactive aleatoriamente neuronas (incluyendo las neuronas de entrada, pero excluyendo las neuronas de salida). Concretamente, cada neurona está determinada por una probabilidad p de ser temporalmente abandonadas, lo que se llama en inglés neuronas en estado *dropped-out*. Esto significa que, las neuronas que pertenezcan en este estado serán totalmente ignoradas durante el entrenamiento. El hiperparamètmetre p se denomina **tasa de abandono** o **dropout rate** y normalmente se sitúa en el 50%, es decir, p = 0.5. Este valor p es totalmente fluctuable y no se rigue por reglas concretas.

  Pues en nuestro caso fijaremos este parametro en p = 0.3

Code:

```
model = Sequential() LeakyReLU = lambda x: tf.keras.activations.relu(x, alpha=0.1) model.add(Conv2D(32, kernel_size = (3, 3), activation = LeakyReLU, padding="same", input_shape=(pf, pc, 1))) model.add(MaxPooling2D((2, 2))) model.add(Dropout(0.3)
```

6.1.2 Modelo Parte 2

- **Capa convolucional 2D**:
  - **Filtros**: 64
  - **kernel_size**: (3 x 3)
  - **activation**: Utilitzamos la función `LeakyReLU`
  - **input_shape**: 28 x 28
- **MaxPooling2D**: (2, 2)
- **Dropout**: 0.5

Code:

```
model.add(Conv2D(64, kernel_size = (3, 3), activation = LeakyReLU, input_shape=(pf, pc, 1))) model.add(MaxPooling2D((2, 2))) model.add(Dropout(0.5))
```

6.1.3 Modelo Parte 3

- **Capa convolucional 2D**:
  - **Filtros**: 128
  - **kernel_size**: (3 x 3)
  - **activation**: Utilitzamos la función `LeakyReLU`
- **Flatten**: Esta capa aplana la entrada y Se usa sin parametros
- **Dense**:
  - **unidades**: 128 (debe ser positivo)

    - **activation**: Utilitzamos la función `LeakyReLU` .
- **Dropout**: 0.3
- **Dense - Fully Connected**: Esta es la capa final (completamente conectada).
    - **unidades**: Numero de categorias a predecir, en nuestro caso, 10.
    - **activation**: `softmax` (estándar para la clasificación multiclase)

```
import tensorflow as tf
from tensorflow.python.keras.models import Sequential
from tensorflow.python.keras.layers import Dense, Flatten, Conv2D, Dropout, MaxPooling2D



#Parte 1 del modelo
model = Sequential()

LeakyReLU = lambda x: tf.keras.activations.relu(x, alpha=0.1)
model.add(Conv2D(32,
                 kernel_size = (3, 3),
                 activation = LeakyReLU,
                 padding="same",
                 input_shape=(pf, pc, 1)))
model.add(MaxPooling2D((2, 2)))
model.add(Dropout(0.3))


#Parte 2 del modelo
model.add(Conv2D(64,
                 kernel_size = (3, 3),
                 activation = LeakyReLU,
                 padding="same"))
model.add(MaxPooling2D(pool_size = (2, 2)))
model.add(Dropout(0.5))


#Parte 3 del modelo
model.add(Conv2D(128, (3, 3), activation = LeakyReLU))
model.add(Flatten())                              # Flatemos el tensor de pixeles:
model.add(Dense(128, activation = LeakyReLU))
model.add(Dropout(0.3))
model.add(Dense(n_cat, activation = 'softmax'))    # La ultima capa debe ser el nº de lables a predecir

```

Ahora que hemos definido como sera la red neuronal ahora, debemos elegir la **función de coste**, un **optimizador** y las **métricas de rendimiento**, es decir, la **compilación** del modelo.

En nuestero caso eligiremos lo siguiente:

- **FUNCIÓN DE COSTE** --> `categorical_crossentrop` : Para un problema de clasificación como el nuestro que tiene 10 clases posibles etiquetas, necesitamos usar la función de pérdida llamada `categórica_crossentropy` .
- **OPTIMIZADOR** --> `adam` : Una de las partes más importantes del modelo es la elección del método de optimización. La elección del algoritmo de optimitzaci023 marca la diferencia entre buenas y malas predicciones. En nuestro caso, hemos seleccionado el algoritmo de optimización *Adam*) (existen otros como el stochastic gradiente descent (SGD), Mini-batch gradiente descent (MBGD), ...), el cual es extensión del SGD. Adam, según los autorses, es computacionalmente eficiente, necesita pocos requisitos de memoria y, además, es adecuado para grandes cantidades de datos.
- **MÉTRICA DE RENDIMIENTO** --> `Accuracy` . Nos ayudará a validar el modelo

```
model.compile(loss = keras.losses.categorical_crossentropy,
              optimizer = 'adam',
              metrics = ['accuracy'])
```

```
model.summary()
```

```
Model: "sequential"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
conv2d (Conv2D)              (None, 28, 28, 32)        320
_________________________________________________________________
max_pooling2d (MaxPooling2D) (None, 14, 14, 32)        0
_________________________________________________________________
dropout (Dropout)            (None, 14, 14, 32)        0
_________________________________________________________________
conv2d_1 (Conv2D)            (None, 14, 14, 64)        18496
_________________________________________________________________
max_pooling2d_1 (MaxPooling2 (None, 7, 7, 64)          0
_________________________________________________________________
dropout_1 (Dropout)          (None, 7, 7, 64)          0
_________________________________________________________________
conv2d_2 (Conv2D)            (None, 5, 5, 128)         73856
_________________________________________________________________
flatten (Flatten)            (None, 3200)              0
_________________________________________________________________
dense (Dense)                (None, 128)               409728
_________________________________________________________________
dropout_2 (Dropout)          (None, 128)               0
_________________________________________________________________
dense_1 (Dense)              (None, 10)                1290
=================================================================
```

```
Total params: 503,690
Trainable params: 503,690
Non-trainable params: 0
_________________________________________________________________
```

```
batch = 70
epocas = 50

train_model = model.fit(X_train, Y_train,
                        batch_size = batch,
                        epochs = epocas,
                        verbose = 1,
                        validation_data = (X_val, Y_val))
```

```
Epoch 18/50
600/600 [==============================] - 81s 136ms/step - loss: 0.2006 - accuracy: 0.9244 - val_loss: 0.2192 - val_accuracy: 0.9244
Epoch 19/50
600/600 [==============================] - 80s 133ms/step - loss: 0.1985 - accuracy: 0.9265 - val_loss: 0.2266 - val_accuracy: 0.9219
Epoch 20/50
600/600 [==============================] - 80s 134ms/step - loss: 0.1959 - accuracy: 0.9256 - val_loss: 0.2192 - val_accuracy: 0.9216
Epoch 21/50
600/600 [==============================] - 80s 134ms/step - loss: 0.1946 - accuracy: 0.9259 - val_loss: 0.2307 - val_accuracy: 0.9226
Epoch 22/50
600/600 [==============================] - 81s 136ms/step - loss: 0.1913 - accuracy: 0.9280 - val_loss: 0.2282 - val_accuracy: 0.9225
Epoch 23/50
600/600 [==============================] - 82s 137ms/step - loss: 0.1861 - accuracy: 0.9292 - val_loss: 0.2349 - val_accuracy: 0.9234
Epoch 24/50
600/600 [==============================] - 80s 133ms/step - loss: 0.1874 - accuracy: 0.9285 - val_loss: 0.2376 - val_accuracy: 0.9147
Epoch 25/50
600/600 [==============================] - 80s 133ms/step - loss: 0.1810 - accuracy: 0.9321 - val_loss: 0.2260 - val_accuracy: 0.9216
Epoch 26/50
600/600 [==============================] - 81s 135ms/step - loss: 0.1817 - accuracy: 0.9307 - val_loss: 0.2331 - val_accuracy: 0.9232
Epoch 27/50
600/600 [==============================] - 80s 133ms/step - loss: 0.1739 - accuracy: 0.9343 - val_loss: 0.2337 - val_accuracy: 0.9231
Epoch 28/50
600/600 [==============================] - 80s 133ms/step - loss: 0.1769 - accuracy: 0.9338 - val_loss: 0.2255 - val_accuracy: 0.9244
Epoch 29/50
600/600 [==============================] - 80s 133ms/step - loss: 0.1746 - accuracy: 0.9331 - val_loss: 0.2570 - val_accuracy: 0.9146
Epoch 30/50
600/600 [==============================] - 79s 132ms/step - loss: 0.1714 - accuracy: 0.9344 - val_loss: 0.2291 - val_accuracy: 0.9233
Epoch 31/50
600/600 [==============================] - 81s 135ms/step - loss: 0.1684 - accuracy: 0.9356 - val_loss: 0.2435 - val_accuracy: 0.9158
Epoch 32/50
600/600 [==============================] - 96s 160ms/step - loss: 0.1728 - accuracy: 0.9344 - val_loss: 0.2326 - val_accuracy: 0.9209
Epoch 33/50
600/600 [==============================] - 83s 138ms/step - loss: 0.1680 - accuracy: 0.9353 - val_loss: 0.2341 - val_accuracy: 0.9221
Epoch 34/50
600/600 [==============================] - 81s 136ms/step - loss: 0.1688 - accuracy: 0.9361 - val_loss: 0.2190 - val_accuracy: 0.9258
Epoch 35/50
600/600 [==============================] - 89s 148ms/step - loss: 0.1640 - accuracy: 0.9384 - val_loss: 0.2360 - val_accuracy: 0.9244
Epoch 36/50
600/600 [==============================] - 95s 158ms/step - loss: 0.1663 - accuracy: 0.9375 - val_loss: 0.2369 - val_accuracy: 0.9238
Epoch 37/50
600/600 [==============================] - 80s 134ms/step - loss: 0.1630 - accuracy: 0.9370 - val_loss: 0.2366 - val_accuracy: 0.9217
Epoch 38/50
600/600 [==============================] - 91s 151ms/step - loss: 0.1614 - accuracy: 0.9386 - val_loss: 0.2301 - val_accuracy: 0.9232
Epoch 39/50
600/600 [==============================] - 81s 134ms/step - loss: 0.1578 - accuracy: 0.9405 - val_loss: 0.2447 - val_accuracy: 0.9191
Epoch 40/50
600/600 [==============================] - 80s 134ms/step - loss: 0.1567 - accuracy: 0.9406 - val_loss: 0.2336 - val_accuracy: 0.9214
Epoch 41/50
600/600 [==============================] - 80s 133ms/step - loss: 0.1592 - accuracy: 0.9399 - val_loss: 0.2314 - val_accuracy: 0.9248
Epoch 42/50
600/600 [==============================] - 87s 145ms/step - loss: 0.1529 - accuracy: 0.9409 - val_loss: 0.2352 - val_accuracy: 0.9229
Epoch 43/50
600/600 [==============================] - 85s 141ms/step - loss: 0.1543 - accuracy: 0.9419 - val_loss: 0.2325 - val_accuracy: 0.9237
Epoch 44/50
600/600 [==============================] - 82s 136ms/step - loss: 0.1523 - accuracy: 0.9424 - val_loss: 0.2317 - val_accuracy: 0.9266
Epoch 45/50
600/600 [==============================] - 82s 137ms/step - loss: 0.1524 - accuracy: 0.9421 - val_loss: 0.2252 - val_accuracy: 0.9293
Epoch 46/50
600/600 [==============================] - 89s 148ms/step - loss: 0.1545 - accuracy: 0.9424 - val_loss: 0.2357 - val_accuracy: 0.9246
Epoch 47/50
```

Evaluacion del modelo

```
score = model.evaluate(x_test, y_test, verbose = 0)
print('Perdida/Loss Test:', score[0])
print('Precision/Accuracy Test:', score[1])
```

```
Perdida/Loss Test: 0.2094968557357788
Precision/Accuracy Test: 0.930899977684021
```

```
import plotly.graph_objs as go

def interpolation_tracer(x, y, text, mode):
    fig.add_trace(go.Scatter(x = x,
                             y = y,
                             name = text,
                             mode = mode))
    fig.update_yaxes(range=[0,1])
    fig.update_xaxes(title_text = 'Épocas')
    fig.update_yaxes(title_text = 'Loss & Accuracy')

def layout_plot(Titulo):
    fig.update_layout(title = {'text': Titulo},
```

```
                    xaxis_title =  "Accuracy",
                    yaxis_title = "Épocas",
                    legend_title = "Leyenda",
                    font = dict(family = "Courier New, monospace",
                                size = 18,
                                color = "RebeccaPurple"))
hist = train_model.history
acc = hist['accuracy']
val_acc = hist['val_accuracy']
loss = hist['loss']
val_loss = hist['val_loss']
epochs = list(range(1, len(acc) + 1))

fig = go.Figure()
interpolation_tracer(epochs, acc, 'Training accuracy', 'lines+markers')
interpolation_tracer(epochs, val_acc, 'Validation accuracy', 'lines+markers')
layout_plot('<b>Accuracy</b> entrenamiento y validación')
fig.show()

fig = go.Figure()
interpolation_tracer(epochs,loss,'Training loss', 'lines+markers')
interpolation_tracer(epochs,val_loss,'Validation loss', 'lines+markers')
layout_plot('<b>Loss</b> entrenamiento y validación')
fig.show()
```

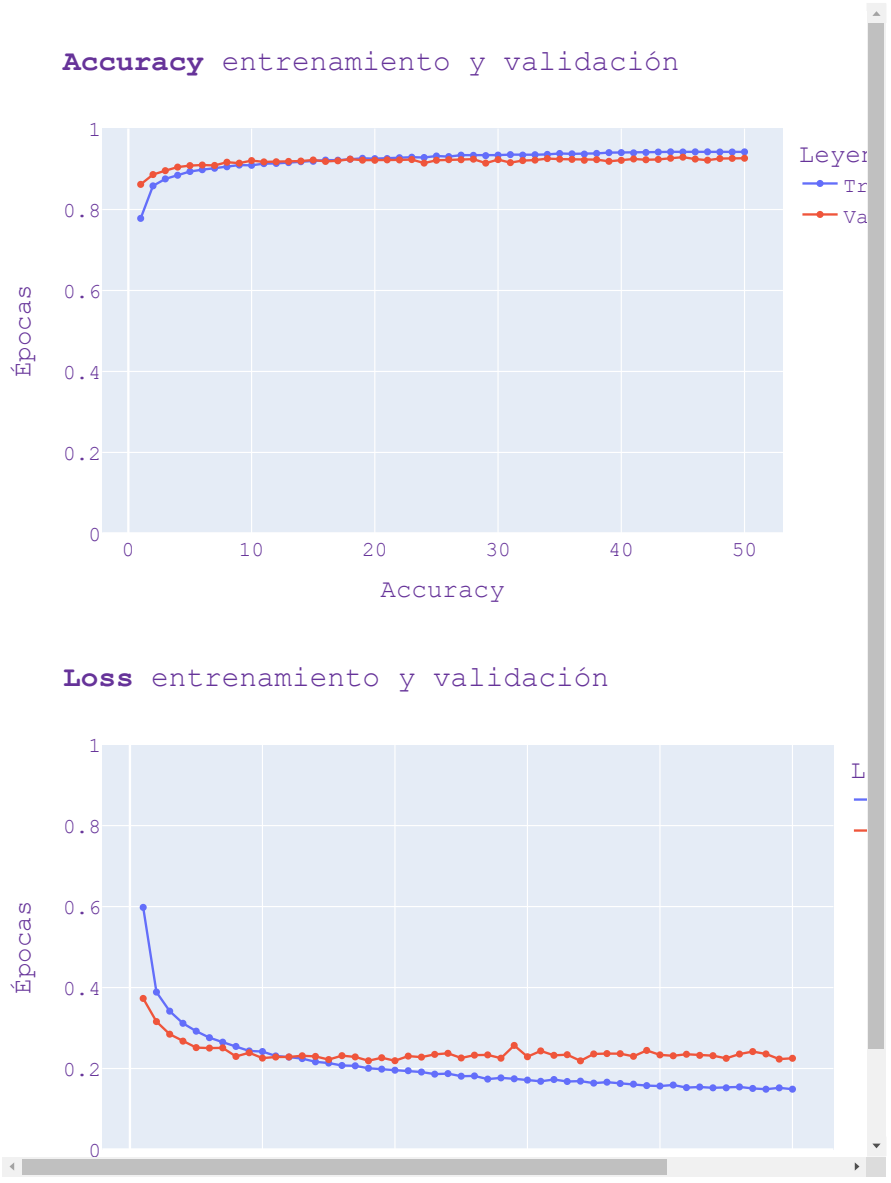

Predicciones en base al modelo

Ahora viene lo divertido, probar el modelo! Para ello, antes nos hemos reservado en conjunto de datos test. Con la función `predict_classes()` llevaremos a cabo esta tarea.

Vamos a realizar las predicciones:

```
pred = model.predict_classes(x_test)
```

```
/usr/local/lib/python3.8/dist-packages/tensorflow/python/keras/engine/sequential.py:454: UserWarning:

`model.predict_classes()` is deprecated and will be removed after 2021-01-01. Please use instead:* `np.argmax(model.predict(x), axis=-1)`,   if your mo
```

pero... realmente que es lo que deberia haber predicho?. Para saber que es lo que deberia haber predicho sacamos las etiquetas reales del conjunto de entrenamiento:

```
y_true = testData.iloc[:,0].to_numpy()
```

Comparamos las etiquetas predecidas con las reales (`pred[:10000] == y_true[:10000]`). Luego, sacamos aquellas que hayan hecho match, es decir, que has sido predecidas correctamente (`== True`). Con la función `np.where()` sacamos el valor de indice (posición) de la etiqueta para saber a que número se refiere y, finalmente, con `[0]` convertimos el resultado de `tupla` a `numpy.ndarray`.

```
n = len(pred[:10000])

GoodPred = np.where((pred[:10000] == y_true[:10000]) == True)[0]
BadPred  = np.where((pred[:10000] == y_true[:10000]) == False)[0]

print('Se han predicho correctamente ' + str(GoodPred.shape[0]) +
      ' clases de ' + str(n) + '.\tAcc: ' + str(round((GoodPred.shape[0]/n)*100, 2)) + '%')

print('Se han predicho erróneamente ' + str(BadPred.shape[0]) +
      ' clases de ' + str(n) + '.\tAcc: ' + str(round((BadPred.shape[0]/n)*100, 2)) + '%')
```

```
Se han predicho correctamente 9309 clases de 10000.     Acc: 93.09%
Se han predicho erróneamente 691 clases de 10000.       Acc: 6.91%
```

Matriz de Confusión: Evaluación de las Predicciones

Una buena herramienta para visualizar sobre que objetos hemos predicho mal, es la matriz de confusión (o clasificación). Esta matriz muestra como ha clasificado el modelo cada cinjunto de prendas.

```
from sklearn.metrics import confusion_matrix
import itertools

def Matriz_de_confusion(cm, clases,  normalize = False, title = 'Matriz de confusión', cmap = plt.cm.Oranges):

    plt.figure(figsize=(10 , 10) , dpi= 70)
    plt.imshow(cm ,
               interpolation = 'nearest' ,
               cmap = cmap )
    plt.suptitle(title, fontsize=20)
    tick_marks = np.arange(len(clases))
    plt.xticks(tick_marks,
               clases,
               rotation = 45 )
    plt.yticks(tick_marks,
               clases)
    fmt = '.2f' if normalize else 'd'
    thresh = cm.max()/2.
    for i, j in itertools.product(range(cm.shape[0]) , range(cm.shape[1]) ):
        plt.text(j, i, format(cm[i, j] , fmt),
        horizontalalignment = "center" ,
        color="white" if cm[ i, j] > thresh else "black" )

    plt.ylabel('Etiquetas reales')
    plt.xlabel('Etiquetas predichas')
```

```
np.set_printoptions(precision = 2)
setLabels = [str(key) + str(': ') + labels[key] for key in labels]


Matriz_de_confusion(confusion_matrix(y_true, pred),
                    clases = setLabels )
```

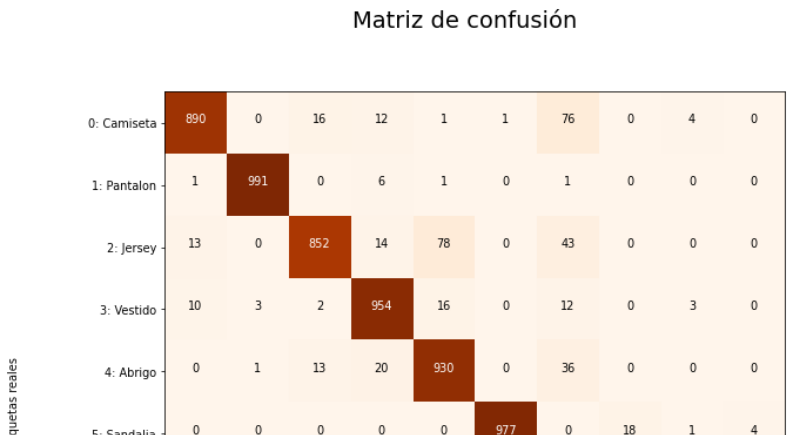

CONCLUSIONES

Para resolver este complejo problema, hemos aplicado técnicas del Deep Learning para la predicción de artículos de ropa con imágenes. Hemos observado que lesprediccions hechas han sido bastante buenas, con un total de **9272** predicciones correctas respecto **728** erróneas.

Concluimos que no ha existido overfitting ya que hemos aplicado técnicas de reducción de la dimensionalidad (MaxPooling2D), capas de regularización (Dropouts), 50 epocas, un batch size de 70 (no se ha estudiado).

Finalmente, con el modelo entrenado, hemos comprobado que predice bastante bien dentro lo que cabe para la resolución de las imágenes. Para confirmar que nuestro modelo puede generalizar, hemos introducido datos nuevos al modelo y este los ha predicho bien.

Confirmamos que el modelo es bueno obteniendo una precisión de ~ 0.927 para los datos test.

REFERENCIAS

[1] Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 2nd Editio, Aurélien GéroN. https://www.oreilly.com

[2] How to use Learning Curves to Diagnose Machine Learning Model Performance, Jason Brownlee. https://machinelearningmastery.com

[3] Activation Functions : Sigmoid, ReLU, Leaky ReLU and Softmax basics for Neural Networks and Deep Learning https://medium.com

[4] FASHION MNIST: Convolutional Neural Network (CNN) https:fashion-mnist-convolutional-neural-network-cnn/notebook